



**CENTRO UNIVERSITÁRIO DO DISTRITO FEDERAL – UDF**  
**COORDENAÇÃO DO CURSO DE CIÊNCIA DA COMPUTAÇÃO**

**Gabriel Gonçalves da Silva**  
**Johnathan Araujo Nunes**  
**Mateus Fonseca da Silva**

**Aplicação de Aprendizado de Máquina na Detecção de Tumores Cerebrais**

**BRASÍLIA**  
**2025**

**Gabriel Gonçalves da Silva**  
**Johnathan Araujo Nunes**  
**Mateus Fonseca da Silva**

**Aplicação de Aprendizado de Máquina na Detecção de Tumores Cerebrais**

Trabalho de conclusão de curso apresentado à Coordenação de Ciência da Computação, do Centro Universitário do Distrito Federal - UDF, como requisito parcial para obtenção do grau de bacharel em 2025

Orientadora: Prof.a Kadidja Valéria  
Reginaldo de Oliveira

**BRASÍLIA**

**2025**

**Johnathan Araujo Nunes**  
**Gabriel Gonçalves da Silva**  
**Mateus Fonseca da Silva**

**Aplicação de Aprendizado de Máquina na Detecção de Tumores Cerebrais**

Trabalho de conclusão de curso apresentado à Coordenação de Ciência da Computação, do Centro Universitário do Distrito Federal - UDF, como requisito parcial para obtenção do grau de bacharel em 2024

Orientadora: Prof.a Kadidja Valéria  
Reginaldo de Oliveira

Brasília, 28 de maio de 2025.

Banca Examinadora

---

NOME DO EXAMINADOR

Titulação

Instituição a qual é filiado

---

NOME DO EXAMINADOR

Titulação

Instituição a qual é filiado

---

NOME DO EXAMINADOR

Titulação

Instituição a qual é filiado

NOTA: \_\_\_\_\_

Dedicamos este trabalho às nossas famílias e aos nossos amigos, que nos apoiaram na realização de tal.

## **AGRADECIMENTOS**

Primeiramente, agradecemos a Deus, por nos dar forças e nos guiar ao longo deste caminho. A nossa orientadora, por todo o apoio, paciência e por cada orientação que fez a diferença na construção deste trabalho.

Agradecemos também aos nossos amigos e colegas, que estiveram ao nosso lado, compartilhando ideias, aprendizados e motivação nos momentos difíceis. E, por fim, nossa gratidão às nossas famílias, pelo amor, compreensão e apoio constantes, que foram essenciais para que pudéssemos chegar até aqui.

“Uma máquina consegue fazer o trabalho de 50 homens ordinários. Nenhuma máquina consegue fazer o trabalho de um homem extraordinário.”

Elbert Hubbard, escritor.

## RESUMO

Este trabalho explora a aplicação da aprendizagem de máquina na detecção de tumores cerebrais, destacando sua relevância para a área da saúde no apoio a diagnósticos mais rápidos e precisos. A pesquisa tem caráter exploratório, qualitativo e descritivo, e foi desenvolvida utilizando o framework Ultralytics, que possibilita a criação, o treinamento e a implementação de modelos de aprendizagem de máquina com suporte à aprendizagem profunda, por meio de uma interface que dispensa codificação direta. O desenvolvimento foi realizado com a linguagem Python e suas bibliotecas, evidenciando sua praticidade e versatilidade. Foram revisados conceitos como tumores cerebrais, ressonância magnética, aprendizagem de máquina e aprendizagem profunda, com a finalidade de compreender os processos de análise realizados pelo modelo. A metodologia usou do código e do banco de dados fornecidos pelo Ultralytics, visando avaliar a eficácia na detecção, segmentação e classificação dos tumores. Como resultado, o estudo contribui para o desenvolvimento da área da saúde mostrando a eficácia do uso de ferramentas tecnológicas voltadas ao suporte de profissionais da saúde em análises médicas futuras.

**Palavra-chave:** Aprendizagem de Máquina, Tumor cerebral, Ultralytics, Ressonância magnética.

## **ABSTRACT**

This paper explores the application of machine learning in the detection of brain tumors, highlighting its relevance to the health sector in supporting faster and more accurate diagnoses. The research is exploratory, qualitative and descriptive, and was developed using the Ultralytics framework, which enables the creation, training and implementation of machine learning models with deep learning support, through an interface that does not require direct coding. Development was carried out using the Python language and its libraries, demonstrating its practicality and versatility. Concepts such as brain tumors, magnetic resonance imaging, machine learning and deep learning were reviewed to understand the analysis processes carried out by the model. The methodology used the code and database provided by Ultralytics to evaluate its effectiveness in detecting, segmenting, and classifying tumors. As a result, the study contributes to the development of the health area by showing the effectiveness of using technological tools to support health professionals in future medical analysis.

**Key words: Machine Learning, Brain Tumors, Ultralytics, Magnetic resonance.**



## LISTA DE ILUSTRAÇÕES

<b>Figura 1 - Exemplos de sintomas de tumor no Cérebro.....</b>	<b>18</b>
<b>Figura 2 - Exame de Ressonância Magnética (RM) do cérebro. ....</b>	<b>19</b>
<b>Figura 3 - Funcionamento do Docker.....</b>	<b>24</b>
<b>Figura 4 – Diagrama do funcionamento do sistema. ....</b>	<b>35</b>
<b>Figura 5 - Resultado Positivo para detecção de tumor. ....</b>	<b>38</b>
<b>Figura 6 – Protótipo da Interface (tela de Login).....</b>	<b>40</b>
<b>Figura 7 – Protótipo da Interface (tela principal).....</b>	<b>40</b>
<b>Figura 8 – Diagrama funcional da interface.....</b>	<b>42</b>
<b>Figura 9 – Protótipo da Interface (tela de análise). ....</b>	<b>43</b>
<b>Figura 10 – Print da conclusão do treinamento de 100 épocas.....</b>	<b>48</b>

## LISTA DE GRÁFICOS

Gráfico 1 – Análise de precisão em 5 épocas. ....	45
Gráfico 2 – Análise de precisão em 8 épocas. ....	46
Gráfico 3 – Análise de precisão em 100 épocas. ....	46

## **LISTA DE ABREVIATURAS E SIGLAS**

### **ABREVIATURAS**

Ex. – Exemplo

### **SIGLAS**

UDF – Centro Universitário do Distrito Federal

CPU – Unidade Central de Processamento

GPU – Unidade de Processamento Gráfico

RM – Ressonância Magnética

AM – Aprendizado de Máquina

API – Interface de Programação de Aplicações

BI – Business Intelligence (Inteligência de Negócios)

RNC – Rede Neural Convolucional (Convolutional Neural Network)

AP –Aprendizagem Profunda (Deep Learning)

IA – Inteligência Artificial

INCA – Instituto Nacional de Câncer

IPAs – Interfaces de Programação de Aplicativos

AM – Aprendizado de Máquina (Machine Learning)

PDI – Processamento Digital de Imagens

RMC – Ressonância Magnética Cerebral

RNC – Redes Neurais Convolucionais

SQL – Structured Query Language

RNR – Rede Neural Recorrente (Recurrent Neural Network)

VGG – Visual Geometry Group (Arquitetura de Rede Neural)

VScode – Visual Studio Code

YOLO – You Only Look Once

## SUMÁRIO

1. Introdução .....	14
1.1 Objetivo Geral .....	15
1.2 Objetivos Específicos .....	15
1.3 Conteúdo e Organização .....	15
2. Referencial Teórico .....	17
2.1 Tumor Cerebral .....	17
2.2 Neuroimagens .....	18
2.2.1 Ressonância Magnética .....	19
2.3 Processamento de Imagens .....	19
2.4 Inteligência Artificial .....	20
2.4.1 Aprendizado de Máquina .....	21
2.4.2 Aprendizagem Profunda .....	22
2.5 Ferramentas .....	22
2.5.1 Visual Studio Code (VScode) .....	22
2.5.2 Python .....	23
2.5.3 Tkinter .....	23
2.5.4 Pillow (PIL) .....	23
2.5.5 Docker .....	24
2.5.6 Ultralytics .....	24
2.5.7 Roboflow .....	25
2.6 Trabalhos Correlatos .....	25
2.6.1 Quadro Comparativo – Trabalhos Correlatos .....	28
3. Aspectos Éticos e Legais .....	32
3.1 Lei Geral de Proteção de Dados (LGPD) .....	32
3.2 Resolução nº 510/2016 do Conselho Nacional de Saúde .....	32
3.3 Resolução nº 510/2016 do Conselho Nacional de Saúde .....	32
3.4 Consentimento e Anonimização .....	33

4. Metodologia .....	34
4.1 Estrutura e Objetivos do Sistema .....	34
4.2 Funcionamento do Sistema .....	34
4.2.1 Coleta e Preparação dos Dados .....	36
4.2.2 Configuração e Arquitetura do Sistema .....	37
4.2.3 Treinamento do Modelo .....	37
4.2.4 Acompanhamento e Monitoramento em Tempo Real.....	37
4.2.5 Avaliação dos Resultados.....	38
4.2.6 Implantação do Sistema .....	39
4.3 Desempenho Computacional e Ajustes de Parâmetros.....	39
4.4 Interface Gráfica para Classificação de Imagens .....	39
4.4.1 Descrição da Interface e Arquitetura da Solução.....	39
4.4.2 Componentes do Sistema.....	39
4.4.3 Funcionamento da Interface .....	41
4.4.4 Perspectivas Futuras .....	43
5. Resultados .....	44
5.1 Introdução aos Resultados .....	44
5.2 Metodologia de Avaliação.....	44
5.3 Resultados Obtidos.....	44
5.3.1 Desempenho do Modelo.....	44
5.4 Eficiência Computacional.....	47
5.5 Análise dos Resultados e Possíveis Ajustes .....	48
5.5.1 Avaliação do Stakeholder .....	48
6. Conclusão e trabalhos futuros .....	50
6.1 Conclusão .....	50
6.2 Trabalhos Futuros.....	51
Referências.....	52

## 1. INTRODUÇÃO

Um tumor cerebral ocorre quando há um crescimento anormal de células em alguma estrutura dentro do crânio, processo que pode ocorrer em qualquer fase da vida, podendo ser classificado como benigno, onde é menos agressivo e de crescimento lento, ou maligno, onde cresce mais rápido. Ambos podem levar ao prejuízo na função normal do sistema nervoso, seja pela doença local ou pela compressão das estruturas saudáveis do cérebro, podendo ter origem do próprio tecido cerebral (neurônios), dos seus envoltórios (por ex.: meninges) ou dos ossos do crânio (tumores cerebrais primários). Porém alguns tumores são oriundos de doenças a distância, que enviam células cancerígenas para o sistema nervoso (metástase cerebral), chamados de tumores cerebrais secundários (Instituto Funcionalitá de Neurologia, mai. 27, 2020).

Em 2020, foi estimado pelo Instituto Nacional de Câncer (INCA), que para cada ano do triênio 2020/2022, sejam diagnosticados no Brasil 11.100 novos casos de tumores cerebrais, sendo 5.870 em homens e 5.230 em mulheres. Segundo a American Cancer Society (2020), no geral, a probabilidade de desenvolvimento de um tumor cerebral durante a vida de um indivíduo é inferior a 1%, sendo de certa forma maior entre as mulheres, embora o risco de um tumor maligno seja maior para o sexo masculino.

De acordo com o artigo de segmentação de imagens médicas com Aprendizagem Profunda - AP (ou, em inglês Deep Learning - DL) da Equipe Data Science Academy (2024), a análise de imagens é uma ferramenta inestimável em medicina. Imagens de ressonância magnética (RM), fornecem um meio efetivo para o mapeamento de imagens que podem alimentar modelos de Aprendizagem Profunda para reconhecimento de tumores cerebrais. O Aprendizado de Máquina - AM (ou, em inglês Machine Learning - ML), subárea Inteligência Artificial (IA) envolvendo o aprendizado de algoritmos a partir de dados, tem ganhado destaque nos últimos anos por sua complexidade moderada e objetivo de aprimoramento em atividades através do treinamento de modelos em dados, podendo ser de aprendizado supervisionado, não supervisionado e por reforço. Dentro da área de AM, a AP utiliza redes neurais mais profundas como Redes Neurais Convolucionais – RNC (ou, em inglês Convolutional Neural Networks - CNN), redes neurais recorrentes - RNR (ou, em inglês Recurrent

Neural Networks - RNN) e Transformers, sendo principalmente aplicável para processamento de dados não estruturados como imagens, texto, entre outros (Equipe Data Science Academy, 2024).

A partir disso, este trabalho propõe a criação de um sistema de AM com o uso do Ultralytics, uma plataforma de IA intuitiva para criar, treinar e implantar modelos de aprendizado de máquina com uma interface sem código e suporte a estrutura de aprendizado profundo (Ultralytics Inc., 2024), que utiliza técnicas de análise e inferência de dados a fim de classificar imagens de RM em diferentes tipos de tumores cerebrais, de modo a facilitar o diagnóstico da doença e a identificação da urgência no tratamento.

### **1.1 Objetivo Geral**

Desenvolver e avaliar um modelo de Aprendizado de Máquina para a detecção, segmentação e classificação de tumores cerebrais a partir de imagens médicas de Ressonância Magnética (RM). O sistema proposto utilizará técnicas avançadas de processamento de imagens e aprendizagem profunda para identificar padrões característicos da doença, proporcionando suporte para prevenção, diagnóstico e planejamento terapêutico.

### **1.2 Objetivos Específicos**

- 1) Implementar e treinar um modelo de Aprendizado de Máquina utilizando o framework Ultralytics, explorando técnicas de segmentação e processamento de imagens de RM, além do uso de aprendizagem profunda para identificação de padrões.
- 2) Apresentar a solução no contexto da precisão e desempenho do modelo desenvolvido, aplicando métricas como acurácia, sensibilidade e especificidade, a fim de validar sua eficácia na distinção entre tumores benignos e malignos.
- 3) Propor melhorias no modelo e analisar sua viabilidade de aplicação clínica, identificando possíveis otimizações nos parâmetros e arquitetura para aprimorar a precisão dos diagnósticos automatizados.

### **1.3 Conteúdo e Organização**

O conteúdo deste artigo está distribuído em sete capítulos.

O primeiro capítulo trata da introdução ao conteúdo trabalhado, percorrendo sobre informações estatísticas sobre os tumores cerebrais, além de uma descrição mais simplificada de cada assunto necessário para o desenvolvimento do artigo, como o Aprendizado de Máquina, Aprendizagem Profunda, entre outros.

No segundo capítulo encontra-se o referencial teórico, onde cada parte conceitual e teórica do artigo é desenvolvida e bem descrita através de dissertações referenciadas e imagens explicativas sobre cada tópico, além de contar com os trabalhos correlatos utilizados para apoiar a fundamentação teórica.

Os aspectos éticos e legais se encontram no terceiro capítulo, onde é tratada toda a legalidade desta pesquisa.

A metodologia, que disserta sobre a abordagem do trabalho, organiza os métodos, justifica as escolhas técnicas e explica o funcionamento do projeto descrito neste trabalho, está situada no quarto capítulo.

O quinto capítulo comporta os resultados analíticos do treinamento do modelo de AM, mostrando-os em gráficos e imagens geradas pelo modelo no Ultralytics com suas respectivas descrições.

No sexto capítulo se encontra a conclusão, que apresenta a síntese dos resultados do modelo YOLOv8, destacando sua eficácia na detecção de tumores cerebrais e a usabilidade da interface gráfica. Reforça a aplicabilidade prática do sistema como ferramenta de apoio ao diagnóstico médico. Além disso, melhorias, expansões e inovações que podem ser aplicadas em versões posteriores do sistema também são propostas.



## 2. REFERENCIAL TEÓRICO

A elaboração do referencial teórico foi feita com base em pesquisas realizadas em plataformas acadêmicas como Google Scholar, Scielo, PubMed e IEEE Xplore, além de sites institucionais confiáveis, como o da Rede D'Or. Foram priorizadas fontes atualizadas, publicadas a partir de 2018, incluindo artigos científicos, dissertações e revisões sistemáticas. A escolha do material levou em conta a relevância para o tema, com foco em estudos que abordam tumores cerebrais, exames de neuroimagem — especialmente ressonância magnética — e a aplicação de técnicas de Machine Learning no apoio ao diagnóstico médico. A organização do referencial seguiu uma lógica que parte da apresentação dos tumores cerebrais e suas características, passa pela importância das imagens médicas e chega ao uso de algoritmos de aprendizado de máquina nesse contexto. Buscamos selecionar apenas trabalhos que realmente dialogam com a proposta do projeto, a fim de garantir uma base teórica sólida e coerente. Além disso, a biblioteca Ultralytics YOLO foi adotada como base prática para o desenvolvimento do trabalho, por oferecer modelos prontos, datasets e recursos de detecção de objetos aplicáveis à análise de imagens médicas.

### 2.1 Tumor Cerebral

“Os tumores no cérebro são neoplasias que ocorrem dentro do crânio e apresentam um desafio importante nas áreas da neurocirurgia e da neurologia. Sua frequência tem aumentado ao longo do tempo, afetando a saúde pública em todo o mundo. A variedade biológica desses tumores leva a uma ampla gama de manifestações clínicas e a respostas diferentes às opções de tratamento disponíveis.” (Cury et al. 2024).

Eles são lesões intracranianas de natureza benigna ou maligna que causam efeitos devido à compressão e infiltração tecidual. (Silva; Oliveira; Acioli, 2009)

Os sintomas podem incluir cefaleias, alterações de personalidade (como ficar deprimido, ansioso ou desinibido), fraqueza, sensações anormais, perda de equilíbrio, dificuldade de concentração, convulsões e falta de coordenação (Bilsky, 2024). À medida que o tumor cresce, ele empurra e alonga, mas normalmente não destrói o tecido nervoso, o que explica os sintomas não se desenvolverem em um primeiro momento (Mafaldo, 2024). A figura 1 exemplifica os sintomas de tumor no cérebro:

**Figura 1 - Exemplos de sintomas de tumor no Cérebro.**



Fonte: Policlínica Neurocor (2024)

Os sintomas de tumor no cérebro podem ser esses especificados na imagem, mas não estão limitados a somente esses. O tratamento de tumor cerebral depende de sua localização, tipo e até mesmo de seu grau de avanço e comprometimento do cérebro. Atualmente, o tumor cerebral pode ser tratado por meio de procedimentos cirúrgicos, quimioterapia, radioterapia e até mesmo de terapia-alvo (Rede Dor, 2024).

## **2.2 Neuroimagens**

Neuroimagem é uma área da ciência que estuda a estrutura e a função do cérebro humano por meio de técnicas de imagem (Fidelis, 2024).

“A de um modo geral, técnicas de neuroimagem funcional são úteis ao possibilitar a investigação do funcionamento cerebral diante de uma demanda específica, o que contribui para o entendimento da neurobiologia associada a habilidades cognitivas, emocionais e comportamentais.” (Corrê et al., 2021).

Existem diferentes tipos de técnicas de neuroimagem, cada uma com suas características e aplicações específicas (Mosko, 2024). Algumas das principais técnicas utilizadas são Ressonância Magnética (RM) e Processamento Digital de Imagens (PDI).

### 2.2.1 Ressonância Magnética

A Ressonância Magnética é uma técnica de neuroimagem que utiliza campos magnéticos e ondas de rádio para criar imagens detalhadas do cérebro. Essa técnica é não invasiva e não utiliza radiação ionizante, sendo considerada segura para os pacientes. (Mosko, 2024).

“A formação da imagem por ressonância magnética está baseada na troca de energia entre núcleos de átomos de hidrogênio e ondas eletromagnéticas que apresentam, em particular, as mesmas frequências oscilatórias (frequência da onda eletromagnética é igual à frequência do movimento dos átomos de hidrogênio)” (Dmitruk; Lopes; Santos, 2021).

Entre as técnicas de neuroimagem, a ressonância magnética se destaca pela sua não-invasividade e especialmente pela sua versatilidade para estudos de natureza estrutural ou funcional do cérebro humano (Salmon; Leoni. 2019). A figura 2 exemplifica uma Ressonância Magnética (RM) do cérebro.

**Figura 2 - Exame de Ressonância Magnética (RM) do cérebro.**



Fonte: Artigo - Imagens e o Ensino de Física: Implicações da Teoria da Dupla Codificação (2016)

### 2.3 Processamento de Imagens

O processamento digital de imagens é a manipulação de dados digitais, com a ajuda de um hardware e software de computador, para produzir mapas digitais onde se extraem e destacam informações específicas de interesse (Oliveira, 2022). Para esse caso, sempre partimos do princípio de que existe uma imagem original e que

esta é trabalhada em um processador de imagens para ser manipulada de acordo com um objetivo (Pichetti et al. 2022).

Gonzalez; Woods. (2009) acrescentam

“Uma imagem pode ser definida como uma função bidimensional,  $f(x, y)$ , em que  $x$  e  $y$  são coordenadas espaciais(planos), e a amplitude de  $f$  em qualquer par de coordenadas  $(x, y)$  é chamada de intensidade ou nível de cinza da imagem nesse ponto. Quando  $x, y$  e os valores de intensidade de  $f$  são quantidades finitas e discretas, chamamos de imagem digital.”

Na medicina, a tecnologia é utilizada no diagnóstico de doenças, podendo ser aplicada em raios-X, Ressonâncias Magnéticas (RM) e entre outros exames.

A utilização do processamento de imagens na Medicina começa com a aquisição de imagens médicas, que são então processadas para realçar ou identificar certos atributos. Isso pode incluir ajustes de contraste e brilho, remoção de ruídos, segmentação de imagens e a transformação de imagens para melhor visualização. (Open-cadd, 2024).

## **2.4 Inteligência Artificial**

A Inteligência Artificial (IA) é um campo da ciência da computação dedicado a desenvolver sistemas capazes de executar tarefas que normalmente necessitariam do discernimento humano. Isso abrange uma ampla gama de capacidades, que incluem aprender, raciocinar, entender linguagem humana e até criar arte. A IA visa equipar máquinas com uma forma de “inteligência”, possibilitando que elas realizem atividades complexas de maneira independente. (Augusto, 2024).

O Aprendizado de Máquina e a IA são frequentemente abordados juntos, e os termos às vezes são usados de forma intercambiável, mas não significam a mesma coisa. Uma distinção importante é que, embora todo Aprendizado de Máquina seja IA, nem toda IA é Aprendizado de Máquina (Oracle 2024). Dentro da IA, uma área de estudo que merece destaque especial é a de Aprendizado de Máquina (AM) (Cerri; Carvalho. 2019).

As aplicações da IA na saúde pública podem agilizar e otimizar estruturas de dados alojados em diferentes sistemas complexos. Cuidar e tratar de pacientes requer uma associação de diferentes passos e recursos. Algoritmos com algum grau de predição poderão ajudar na precisão de tratamentos e diminuição de eventuais erros médicos. (Valdati, 2020).

### 2.4.1 Aprendizado de Máquina

“É a área da Inteligência Artificial em que se atribui à máquina a capacidade de aprender por intermédio dos dados, ou seja, da experiência, sem a necessidade de detalhar as relações fenomenológicas existentes no problema a ser resolvido, utilizando-se para isto apenas métodos clássicos de modelagem experimental (por exemplo, o recozimento simulado) e/ou de Inteligência Artificial, sendo que estes últimos são inspirados em alguma funcionalidade do corpo humano (por exemplo, o cérebro humano) ou no comportamento característico de um grupo de animais (por exemplo, a colônia de formigas ou o voo das aves)”. (Oscar. 2023).

O AM é empregado para resolver problemas de predição (regressão e reconhecimento de padrões), de modo a obter o valor de uma variável de saída, com base em modelos matemáticos que mapeiam as entradas nas saídas, de acordo com uma relação de causa e efeito bem definida entre elas. (Oscar. 2023).

Algoritmos de aprendizado de máquina podem ser classificados, de maneira geral, em três categorias:

#### Aprendizagem Supervisionada:

No Aprendizado Supervisionada, para cada exemplo apresentado ao algoritmo de aprendizado é necessário apresentar a resposta desejada (ou seja, um rótulo informando a que classe o exemplo pertence, no caso de um problema de classificação de imagens, por exemplo, como distinguir imagens de gatos e de cachorros). (Ludermir.2021).

#### Aprendizagem Não Supervisionada:

Aprendizado não supervisionada é um algoritmo de aprendizado de máquina que aprende algumas características de informações de entrada. Após fornecer um novo banco de dados, ele utiliza características aprendidas anteriormente para a identificação da classe de dados (Sharma et. Al. 2021).

#### Aprendizagem por reforço:

O aprendizado por reforço, adota uma abordagem de recompensa. O algoritmo é recompensado quando acerta ou punido quando erra, dado um objetivo definido (Abreu, 2023).

A principal diferença entre Aprendizagem Profunda e Aprendizado de Máquina é a estrutura, sendo modelos tradicionais de aprendizado de máquina “não profundos” mais simples com uma ou duas camadas computacionais e os profundos usam três ou mais camadas. (Santos et. Al. 2019).

Quando as classes (diagnósticos ou desfechos clínicos) para a decisão final do modelo são pré-estabelecidas, o processo de treinamento é supervisionado. Quando não existe classe definida, o processo é não supervisionado. (Santos et. Al. 2019).

### **2.4.2 Aprendizagem Profunda**

Aprendizagem Profunda é uma subárea de Aprendizagem de Máquina que investiga técnicas para simular o comportamento do cérebro humano em tarefas como reconhecimento visual, reconhecimento de fala e processamento de linguagem natural. Algoritmos de aprendizagem profunda objetivam produzir representações hierárquicas de alto nível dos dados de entrada, por meio de camadas de processamento sequencial em uma rede neural artificial. (Bezerra. 2016).

A principal diferença entre Aprendizagem Profunda e Aprendizado de Máquina é a estrutura, sendo modelos tradicionais de aprendizado de máquina “não profundos” mais simples com uma ou duas camadas computacionais e os profundos usam três ou mais camadas.

Dessa maneira, na técnica de aprendizado profundo, é minimizada a necessidade de pré-processamento ou segmentação. O método, porém, também apresenta desvantagens, como a necessidade de um conjunto muito grande de imagens (centenas a milhares), maior dependência da qualidade dos exames e dados clínicos e a dificuldade de se identificar a lógica utilizada. (Santos et. Al. 2019).

Como a Ultralytics YOLO possui um grande conjunto de dados e imagens, diante disso ela se torna uma ferramenta muito eficiente.

## **2.5 Ferramentas**

### **2.5.1 Visual Studio Code (VScode)**

O Visual Studio Code, ou VS Code, é um editor de código-fonte desenvolvido pela Microsoft, lançado em 2015. Ele foi projetado para ser leve e extensível permitindo que desenvolvedores de diversas linguagens de programação possam personalizar o ambiente de desenvolvimento de acordo com suas necessidades específicas.

Uma das principais vantagens do Visual Studio Code é sua interface intuitiva e amigável. Mesmo os desenvolvedores novatos podem se sentir confortáveis utilizando-o desde o início. A simplicidade da interface não compromete a funcionalidade, e a experiência do usuário é aprimorada pela capacidade de personalização. Com a

ajuda de extensões e temas, cada desenvolvedor pode adaptar o ambiente de trabalho de acordo com suas preferências e necessidades, criando uma experiência única e mais produtiva. (Providello, 2023).

### **2.5.2 Python**

O Python é uma linguagem de programação amplamente usada em aplicações da Web, desenvolvimento de software, ciência de dados e Aprendizado de Máquina (AM). Os desenvolvedores usam o Python porque é eficiente e fácil de aprender e pode ser executada em muitas plataformas diferentes (Amazon Web Services. 2024).

O Python foi escolhido para o projeto por sua versatilidade, pela ampla disponibilidade de bibliotecas e frameworks que simplificam a implementação e pela sua facilidade de processar imagens.

“A interface Python do YOLO permite integração perfeita em seus projetos Python, facilitando o carregamento, a execução e o processamento da saída do modelo. Projetada com simplicidade e facilidade de uso em mente, a interface Python permite que os usuários implementem rapidamente detecção, segmentação e classificação de objetos em seus projetos. Isso torna a interface Python do YOLO uma ferramenta inestimável para qualquer um que queira incorporar essas funcionalidades em seus projetos Python’ (Ultralytics. 2024).

Para a construção do sistema proposto, foram utilizadas bibliotecas específicas da linguagem Python, escolhidas por sua robustez, ampla documentação e aplicabilidade em projetos de visão computacional e interfaces gráficas.

### **2.5.3 Tkinter**

Tkinter é a biblioteca padrão da linguagem Python para criação de interfaces gráficas (*Graphical User Interfaces – GUI*). Baseada na biblioteca Tcl/Tk, permite o desenvolvimento de janelas, botões, menus e outros elementos interativos de maneira simples e nativa. Sua principal vantagem é não exigir instalações adicionais, sendo integrada ao ambiente padrão de desenvolvimento Python (ASSIS; ALMEIDA, 2021).

### **2.5.4 Pillow (PIL)**

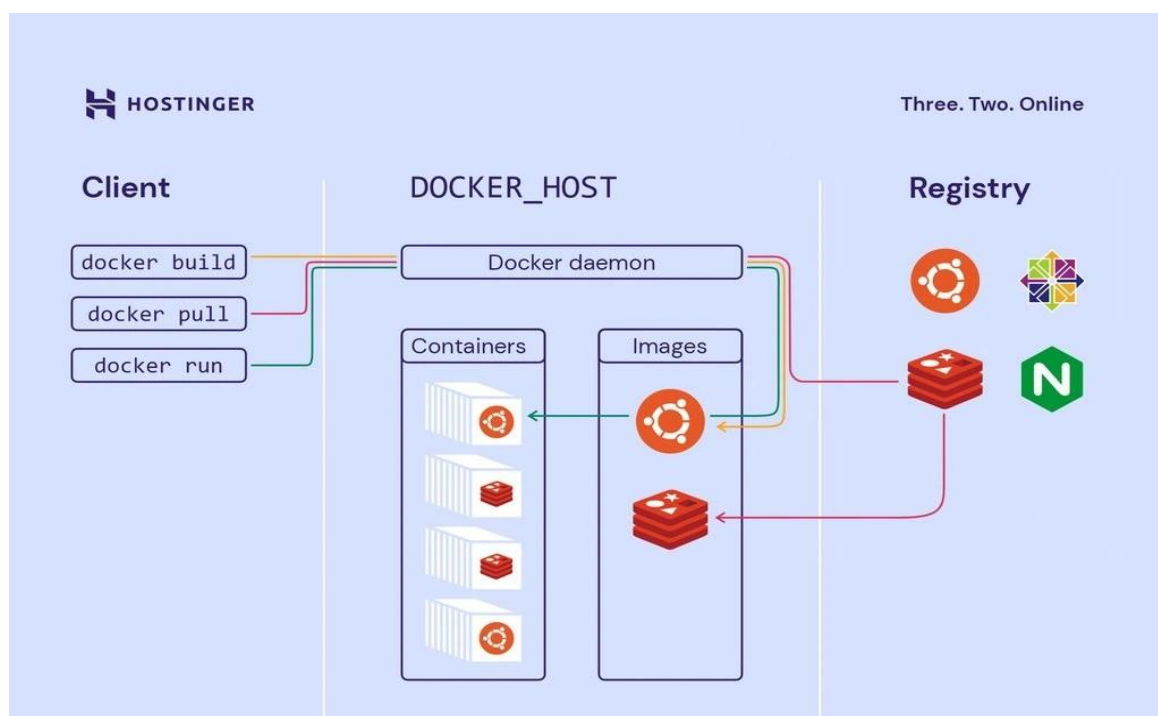
Pillow é uma biblioteca derivada do projeto original PIL (*Python Imaging Library*), amplamente utilizada para manipulação de imagens digitais em Python. Oferece funções para abrir, redimensionar, converter, salvar e aplicar filtros às imagens. No presente trabalho, foi utilizada para o carregamento e exibição de imagens de ressonância magnética na interface gráfica do sistema (PILLOW, 2024).

### 2.5.5 Docker

Docker é uma plataforma que permite que software seja executado em seu próprio ambiente isolado. Depois que o Docker estiver instalado, você simplesmente baixa ou “puxa” - a imagem Docker do SQL Server no Linux para o seu Mac, em seguida, execute-o como um contêiner Docker. Este contêiner é um ambiente isolado que contém tudo o que o SQL Server precisa para ser executado (Calisir. 2020).

A Figura 3 mostra como funciona o Docker:

**Figura 3 - Funcionamento do Docker.**



Fonte: HOSTINGER (2025)

### 2.5.6 Ultralytics

Ultralytics YOLO é um avanço da série YOLO para detecção de objetos e segmentação de imagens em tempo real. Ele se baseia em versões anteriores, introduzindo novos recursos e melhorias para melhorar o desempenho, a flexibilidade e a eficiência. A YOLO oferece suporte a várias tarefas de IA de visão, como detecção, segmentação, estimativa de pose, rastreamento e classificação. Sua arquitetura de última geração garante velocidade e precisão superiores, tornando-o adequado para diversas aplicações, incluindo dispositivos de borda e Interfaces de Programação de Aplicativos - IPAs (ou em inglês, Application Programming Interface – API) de nuvem (Ultralytics Inc., 2024).



O Ultralytics YOLO é muito utilizado em aplicações como segurança, veículos independentes, monitoramento ambiental, diagnóstico médico e sistemas industriais. Ele fornece uma interface simplificada para desenvolvedores, com modelos pré-treinados que podem ser ajustados para tarefas específicas. Além disso, sua escalabilidade o torna adequada tanto para aplicações em dispositivos embarcados quanto em sistemas baseados na nuvem, garantindo acessibilidade e eficiência em diferentes ambientes. (Ultralytics Inc., 2024).

### **2.5.7 Roboflow**

Roboflow é uma plataforma de visão computacional que permite aos usuários treinar e implantar modelos de detecção de objetos em tempo real. A plataforma simplifica muitos dos desafios associados à construção de modelos de visão computacional, incluindo pré-processamento de dados, treinamento e implantação. É uma ferramenta poderosa que pode ajudar a criar rapidamente conjuntos de dados de treinamento para detecção de objetos em tempo real. Usando o Roboflow, é possível importar e rotular imagens, além de ajustar e visualizar as anotações.

## **2.6 Trabalhos Correlatos**

Em seu artigo, Lupianez Filho, J. R. (2023) propõe a previsão da recorrência de tumores cerebrais utilizando técnicas de Aprendizado de Máquina. Para isso, utilizou um dataset do Kaggle e construiu modelos preditivos no Google Colab, com uso da linguagem Python e bibliotecas especializadas no pré-processamento de dados. O estudo demonstrou a eficiência das redes neurais com uma acurácia de 98,67%, F1 Score de 99,04% e recall de 99,28%, evidenciando a relevância do uso de algoritmos preditivos no acompanhamento médico de tumores cerebrais.

Na proposta de Garzillo, et al, (2022) é apresentada uma aplicação prática de algoritmos de Aprendizado de Máquina na classificação de tumores cerebrais com imagens de ressonância magnética. O estudo utilizou algoritmos supervisionados, como Support Vector Machine, Random Forest e K-Nearest Neighbors, para classificar amostras de tumores como benignos ou malignos, alcançando alta precisão. O trabalho também demonstrou várias técnicas de pré-processamento para otimizar o desempenho dos modelos, como a padronização e a redução de características do conjunto de dados.

O projeto de Teixeira, et al, (2024) desenvolveu uma Rede Neural Convolutio-  
nal baseada na arquitetura VGG16 para detecção de tumores cerebrais, utilizando o

dataset Br35H Detecção de Tumor (Tumor Detection) 2020. Com o suporte de ferramentas como Python, TensorFlow, Keras, Numpy e Matplotlib no Google Colab, o modelo mostrou-se eficaz na análise de imagens médicas, destacando o impacto da Inteligência Artificial e do aprendizado profundo na área da saúde.

O estudo de Costa Junior, F. V. L. (2023) utilizou duas arquiteturas distintas de visão computacional que foram empregadas para realizar uma comparação abrangente: as RNCs e Transformadores (Transformers) com o objetivo central de identificar qual dessas se destaca na tarefa proposta. Após o treinamento e teste dos modelos para reconhecer e classificar as imagens como 0 (Sem tumor cerebral) e 1 (Com tumor cerebral), os resultados revelaram que ambos obtiveram um bom desempenho, porém, para alguns modelos de RNCs houve a necessidade de um maior número de épocas.

Desenvolvendo seu trabalho, Domingues Braga, P. H. (2023) realizou uma comparação entre 4 arquiteturas de aprendizado profundo, AlexNet, VGG, GoogLeNet e ResNet, com o objetivo de identificar qual modelo apresenta melhor desempenho na classificação de tumores a partir do aprendizado através das imagens de ressonância magnética dos tumores e suas variações. A métrica de desempenho utilizada como parâmetro de comparação foi a precisão, a qual foi estabelecida em 95% dado o objetivo de identificar o maior número possível de tumores cerebrais. O modelo que obteve o melhor resultado foi o que utilizou a arquitetura AlexNet, alcançando 100% de precisão na classificação de carcinomas e 84% de acurácia geral. Foram utilizados os recursos do Google Colaboratory, Google Drive e bibliotecas da linguagem Python sem nenhum custo financeiro.

Como proposta, de Almeida, A. C. N. (2024) apresenta uma análise de imagens de Ressonância Magnética Cerebral (RMC) em um classificador binário, para determinação de presença ou ausência de tumor, fazendo uso de RNC. Durante o trabalho todas as etapas foram contempladas, desde o tratamento das imagens, a modulação e treinamento do modelo, até a avaliação da sua acurácia. A acurácia alcançada no modelo foi de 0.99 em treino e 0.90 em validação. Mesmo com um valor considerado alto, foram abordadas formas de se otimizar o modelo, e discutidos problemas que foram evitados com técnicas específicas durante a modelagem. Um dos principais aspectos a ser analisado é o impacto da abordagem de Transferência de Aprendizado, que possibilitou alcançar alta acurácia mesmo com um banco de dados de tamanho

modesto. Nesse contexto, destaca-se também a escolha do modelo VGG19. O modelo VGG é amplamente utilizado em estudos de reconhecimento de imagens, sendo as versões VGG16 e VGG19 as mais recentes. Neste trabalho, optou-se pelo VGG19, por possuir mais camadas convolucionais, o que permite uma definição mais precisa e detalhada das características do conjunto de dados.

Em seu estudo, Sadrawi, M. (2023), utilizou vários modelos YOLOv5 para localizar a parte tumoral no cérebro, utilizando diversas imagens cerebrais com suas máscaras correspondentes. A entrada do modelo tinha dimensões de 640 x 640 pixels e a saída do modelo YOLOv5 consistiu nas classes detectadas com suas caixas delimitadoras (*bounding boxes*): centro X, centro Y, largura e altura. A saída também forneceu a probabilidade associada a uma classe detectada. As avaliações foram baseadas na perda da caixa delimitadora (*bounding box loss*), perda de objetividade (*objectness loss*), precisão, revogação e médias de precisão (*mean average precision*). Além disso, é realizada uma investigação sobre o tempo de inferência para estimar o tempo necessário para a predição. Analisando uma amostragem da convergência do modelo durante a sessão de treinamento, foi observado que, em relação à perda da caixa delimitadora, os modelos YOLOv5l, YOLOv5m e YOLOv5x apresentaram melhor convergência ao produzir erros quadráticos médios (*mean squared error*, MSE) mais baixos do que os modelos YOLOv5n e YOLOv5s, além de apresentarem oscilações relativamente menores.

O projeto de Mazón, M. J. C. (2024) consistiu no desenvolvimento de um sistema baseado em inteligência artificial para a classificação e detecção de tumores cerebrais em imagens de ressonância magnética. Inicialmente focado na classificação dos tumores em categorias específicas (glioma, meningioma, pituitário e ausência de tumor) utilizando redes neurais como MobileNetV2, o trabalho evoluiu para incluir a detecção precisa da localização dos tumores, essencial para o planejamento clínico. Duas abordagens foram implementadas e comparadas: Faster R-CNN, que apresentou dificuldades em distinguir certas classes e obteve resultados limitados, e YOLOv8, que mostrou melhor desempenho, alcançando maior precisão na identificação e localização dos tumores, embora ainda apresentasse algumas confusões. O projeto destacou a importância da colaboração interdisciplinar, do uso de dados bem etiquetados por especialistas médicos e da adoção de técnicas avançadas de aprendizado profundo para alcançar resultados robustos e clínicos.

O trabalho de Moreira A. G. (2024) propõe um sistema de classificação de tumores cerebrais a partir de imagens de RM, utilizando técnicas de aprendizado profundo com Aprendizagem por Transferência (ou, em inglês Transfer Learning), que utiliza modelos de RNC pré-treinados em conjuntos de dados, aplicando o conhecimento já adquirido. Foram empregados cinco modelos pré-treinados: AlexNet, DenseNet201, EfficientNetB7, MobileNetV2 e ResNet50, com otimização de hiper parâmetros via Grid Search e validação cruzada k-fold. O processo envolveu o pré-processamento das imagens de RM, aumento de dados e avaliação do desempenho com métricas como acurácia, precisão, recall, F1-score e especificidade. Além disso, testes estatísticos foram realizados para verificar se os resultados foram significativos. O modelo EfficientNetB7 obteve o melhor desempenho, atingindo 97,68% de acurácia, se mostrando mais robusto até quando validado externamente, utilizando bases de dados independentes.

### **2.6.1 Quadro Comparativo – Trabalhos Correlatos**

Para avaliar a eficiência do modelo Ultralytics YOLOv8 no reconhecimento de tumores cerebrais em imagens de ressonância magnética (RM), realizou-se um comparativo com diferentes abordagens descritas na literatura recente. Cada estudo apresenta particularidades quanto ao tipo de modelo empregado, base de dados utilizada, métricas avaliadas e resultados obtidos.

O modelo YOLOv8, desenvolvido pela Ultralytics, destaca-se por seu desempenho em tarefas de detecção com alta velocidade de inferência e precisão. Nos testes realizados neste trabalho, o modelo apresentou uma média de precisão (mAP@0.5) em torno de 0,96, com ótima capacidade de localizar e classificar a presença de tumores cerebrais por meio de bounding boxes, utilizando imagens com dimensões padrão de 640x640 pixels.

No estudo de Lupianez Filho (2023), foram utilizadas redes neurais com alto desempenho preditivo, alcançando acurácia de 98,67%, F1 Score de 99,04% e recall de 99,28% para prever a recorrência de tumores. Tais métricas são superiores às encontradas em muitas aplicações tradicionais e indicam uma forte capacidade de generalização dos modelos.

Garzillo et al. (2022) exploraram algoritmos supervisionados como SVM, Random Forest e KNN para classificar tumores como benignos ou malignos, destacando

o uso de técnicas de pré-processamento, embora não tenham fornecido métricas numéricas exatas.

Teixeira et al. (2024) adotaram uma Rede Neural Convolucional baseada na arquitetura VGG16 utilizando o dataset Br35H Tumor Detection 2020, mostrando-se eficaz na análise das imagens médicas, ainda que os resultados quantitativos não tenham sido reportados no resumo da proposta.

Já Costa Junior (2023) comparou RNCs e Transformers na detecção de tumores, identificando que ambos os modelos apresentaram desempenho satisfatório, porém com maior exigência computacional por parte das redes convolucionais.

Domingues Braga (2023) avaliou quatro arquiteturas (AlexNet, VGG, GoogLeNet e ResNet), sendo que a AlexNet alcançou 100% de precisão na detecção de carcinomas e uma acurácia geral de 84%. Esse resultado reforça a eficácia da AlexNet na identificação de padrões específicos, embora seu desempenho geral seja inferior ao de outras abordagens.

A proposta de Almeida (2024) utilizou a arquitetura VGG19 com técnicas de transferência de aprendizado, atingindo 99% de acurácia no treinamento e 90% na validação. Esse trabalho evidenciou a eficiência de abordagens transfer learning em cenários com bases de dados reduzidas.

No estudo de Sadrawi (2023), foram utilizados diversos modelos YOLOv5, sendo observada melhor convergência nos modelos YOLOv5l, YOLOv5m e YOLOv5x. A análise incluiu perda de objetividade, perda de bounding box e média de precisão, o que reforça a eficiência das versões mais robustas da linha YOLOv5.

Mazón (2024) comparou os modelos MobileNetV2, Faster R-CNN e YOLOv8, sendo este último o que apresentou melhor desempenho na tarefa de detecção e localização de tumores, embora ainda apresentasse desafios quanto à distinção entre subtipos tumorais.

Moreira (2024) propôs um sistema de classificação de tumores cerebrais baseado em técnicas de AP e transferência de aprendizado, utilizando modelos pré-treinados. Entre eles, o modelo EfficientNetB7 obteve destaque com uma acurácia de 97,68%, mesmo quando validado com bases externas independentes.

Com base nessa análise comparativa, observa-se que o modelo YOLOv8, utilizado neste TCC, se destaca principalmente pela sua eficiência na detecção em

tempo real, alta precisão na localização espacial dos tumores e versatilidade no tratamento de imagens rotuladas. Embora outros modelos, como redes neurais densas (Lupianez Filho, 2023) ou transfer learning com VGG (Almeida, 2024), tenham apresentado acurácias muito elevadas em contextos específicos, o YOLOv8 se sobressai na velocidade de inferência e na capacidade de fornecer não apenas a classificação, mas também a localização precisa do tumor, sendo, portanto, altamente eficaz para aplicações clínicas em tempo real.

Assim, conclui-se que, embora não seja o modelo com a maior acurácia absoluta em todos os casos, o Ultralytics YOLOv8 oferece um equilíbrio superior entre desempenho, rapidez e aplicabilidade clínica, sendo particularmente indicado para sistemas de apoio ao diagnóstico que exigem resposta ágil e interpretação visual da detecção.

A análise foi feita de forma objetiva no quadro comparativo a seguir:

Estudo / Modelo	Tipo / Arquitetura	Métricas Principais	Dataset / Fonte
YOLO (Ultralytics)	YOLOv8 – Detecção em tempo real	Acurácia elevada (depende da versão), mAP alto, baixo tempo de inferência	RM com bounding boxes (ex: BraTS)
Lupianez Filho (2023)	Redes Neurais	Acurácia: 98,67% F1-Score: 99,04% Recall: 99,28%	Kaggle
Garzillo et al. (2022)	SVM, RF, KNN (tradicionais)	Alta precisão	Imagens de RM
Teixeira et al. (2024)	CNN (VGG16)	Não especificado	Dataset Br35H
Costa Junior (2023)	RNCs vs Transformers	Ambos com bom desempenho	Não especificado
Domingues Braga (2023)	AlexNet, VGG, GoogLeNet, ResNet	AlexNet: 100% de precisão em carcinomas Acurácia geral: 84%	RM – Google Colab
Almeida (2024)	VGG19 (Transfer Learning)	Acurácia treino: 0,99 Validação: 0,90	RMC
Sadrawi (2023)	YOLOv5 (várias versões)	mAP, objectness loss, bounding box loss	Imagens com máscaras tumorais
Mazón (2024)	Faster R-CNN vs YOLOv8	YOLOv8 > Faster R-CNN em precisão e localização	Glioma, meningioma, pituitário

Moreira (2024)	AlexNet, DenseNet201, EfficientNetB7, MobileNetV2, ResNet50 (Transfer Learning)	EfficientNetB7 Acurácia: 97,68%	Imagens RM com validação cruzada
----------------	---	------------------------------------	----------------------------------

### **3. ASPECTOS ÉTICOS E LEGAIS**

O presente trabalho, ao lidar com imagens médicas que podem conter dados sensíveis de pacientes, respeita os princípios e diretrizes legais definidos pela legislação brasileira e internacional sobre proteção de dados pessoais.

#### **3.1 Lei Geral de Proteção de Dados (LGPD)**

A Lei nº 13.709, de 14 de agosto de 2018, conhecida como Lei Geral de Proteção de Dados Pessoais (LGPD), estabelece normas para o tratamento de dados pessoais, inclusive nos meios digitais, com o objetivo de proteger os direitos fundamentais de liberdade e de privacidade. De acordo com a LGPD, dados referentes à saúde são considerados sensíveis, exigindo um nível mais elevado de proteção (“BRASIL, 2018”).

No contexto deste trabalho, o uso de imagens médicas será realizado com estrito cumprimento da legislação vigente. Todas as imagens utilizadas foram previamente anonimizadas, ou seja, desvinculadas de qualquer dado que possa identificar diretamente os pacientes, conforme previsto no Art. 12 da LGPD.

#### **3.2 Resolução nº 510/2016 do Conselho Nacional de Saúde**

De acordo com a Resolução nº 510/2016 do Conselho Nacional de Saúde, toda pesquisa envolvendo seres humanos — mesmo de forma indireta, como no uso de dados — deve atender aos princípios éticos da autonomia, beneficência, não maleficência e justiça (“BRASIL, 2016”).

Este projeto seguiu os princípios dessa resolução, assegurando que o uso dos dados tem fins exclusivamente científicos e de melhoria do diagnóstico médico, sem qualquer prejuízo aos indivíduos envolvidos.

#### **3.3 Resolução nº 510/2016 do Conselho Nacional de Saúde**

De acordo com a Resolução nº 510/2016 do Conselho Nacional de Saúde, toda pesquisa envolvendo seres humanos — mesmo de forma indireta, como no uso de dados — deve atender aos princípios éticos da autonomia, beneficência, não maleficência e justiça (“BRASIL, 2016”).

Este projeto seguiu os princípios dessa resolução, assegurando que o uso dos dados tem fins exclusivamente científicos e de melhoria do diagnóstico médico, sem qualquer prejuízo aos indivíduos envolvidos.



### **3.4 Consentimento e Anonimização**

Em conformidade com os princípios éticos da pesquisa, as imagens utilizadas nesta aplicação foram fornecidas por bases públicas que já possuem termos de uso e mecanismos de consentimento pré-estabelecidos. Quando necessário, mecanismos de anonimização foram aplicados para remover qualquer dado que pudesse identificar os pacientes, conforme preconiza o Art. 13 da LGPD (“BRASIL, 2018”).

Além disso, qualquer implementação real em ambiente clínico deverá contar com aprovação de um Comitê de Ética em Pesquisa (CEP) e o consentimento livre e esclarecido dos pacientes.

## 4. METODOLOGIA

Este trabalho explora a aplicação do sistema Ultralytics YOLOv8 na detecção de tumores cerebrais, utilizando algoritmos de aprendizado de máquina e aprendizado profundo voltados à análise de imagens médicas. A metodologia adotada é exploratória, qualitativa e descritiva, permitindo descobrir o potencial dessas tecnologias de forma prática e interpretativa, sem depender de análises estatísticas complexas. O foco qualitativo ajuda a entender os resultados gerados pelo modelo, enquanto a forma descritiva possibilita documentar com clareza todas as etapas do processo.

A escolha do framework Ultralytics, foi pela sua capacidade de realizar tarefas complexas de detecção, segmentação e classificação com alta precisão e agilidade que são características fundamentais para aplicações em diagnósticos médicos. Além disso, a interface da plataforma é acessível, mesmo para quem não possui profundo conhecimento em programação. Todo o sistema foi desenvolvido na linguagem Python e executado em ambientes virtuais Docker, garantindo portabilidade e eficiência no processamento dos dados.

### 4.1 Estrutura e Objetivos do Sistema

O objetivo principal do sistema é realizar a identificação, classificação e segmentação de tumores em imagens médicas cerebrais, de forma que os profissionais da saúde possam utilizá-lo como ferramenta de apoio diagnóstico. Abaixo, são detalhadas as principais funcionalidades do sistema:

1. Detecção de Tumores: Identificação precisa de regiões com características tumorais.

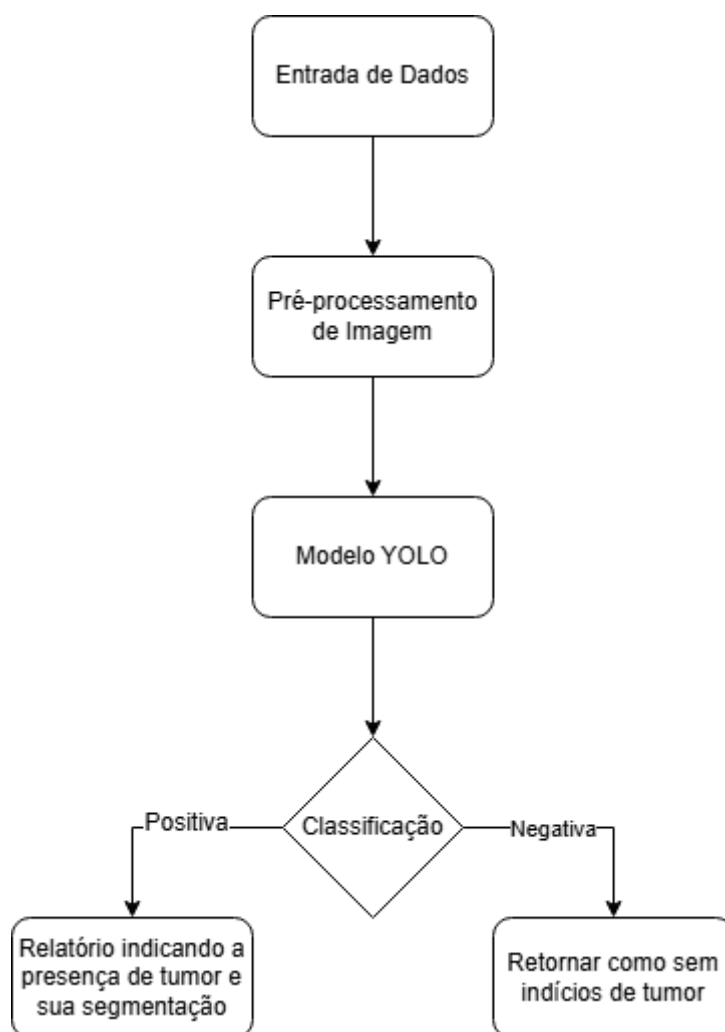
2. Classificação das Lesões: Avaliação e classificação de diferentes tipos e tamanhos de tumores.

3. Segmentação de Imagens: Delimitação das áreas afetadas, para visualização clara e detalhada.

### 4.2 Funcionamento do Sistema

O funcionamento e arquitetura do sistema estão descritos na figura 4 e detalhados posteriormente.

**Figura 4 – Diagrama do funcionamento do sistema.**



Fonte: Elaborado pelos autores com auxílio da ferramenta draw.io (2025)

### **Entrada de Dados**

Descrição:

Imagem de ressonância magnética é recebida pelo sistema.

### **Pré-processamento**

Descrição:

Ajuste de Resolução: Padronizar as dimensões da imagem.

Remoção de Ruído: Aplicação de filtros (ex.: Gaussiano).

Normalização: Ajustar os valores dos pixels para o intervalo adequado (ex.: 0-1 ou -1 a 1).

Segmentação: Delimitar regiões de interesse, como o crânio.

### **Modelo YOLO**

Carregamento do modelo previamente treinado.

Processamento da imagem de entrada.

### **Classificação**

Descrição:

O modelo YOLO, ou outro utilizado, classifica a imagem em:

Tumor presente (positivo).

Tumor ausente (negativo).

Baseado nos padrões aprendidos durante o treinamento.

### **Pós-processamento**

Descrição:

Se Tumor Positivo:

Gerar relatório com:

Localização e dimensões.

Destacar a região detectada.

Se Tumor Negativo:

Registrar o resultado como sem indícios de tumor.

### **Resultado**

Saídas possíveis:

Relatório detalhado para especialistas médicos.

Imagem marcada com as regiões de interesse.

Mensagem de ausência de tumores.

#### **4.2.1 Coleta e Preparação dos Dados**

O conjunto de dados de tumores cerebrais engloba um vasto leque de imagens médicas que apresentam exames cerebrais com e sem tumores.

A base de dados inclui 893 imagens cerebrais para treinamento da máquina, e 223 imagens para serem validadas, totalizando 1016 imagens de diversos ângulos e profundidades. O que permite que o modelo YOLO aprenda com um conjunto e teste sua eficácia em outro, promovendo um ciclo contínuo de aprendizado e ajuste.

Esses dados são pré-processados para assegurar que estejam no formato e na qualidade ideais, com imagens padronizadas e etiquetadas (anotadas) conforme a presença ou ausência de tumores. Esse processo garante que o modelo receba entradas consistentes, o que melhora a eficácia da aprendizagem.

As imagens se localizam numa pasta de nome 'train', de onde as imagens se encaminham para o processamento, sendo enviadas para uma outra pasta, 'valid',

onde se encontram todas as imagens que possuem os parâmetros necessários para a análise do modelo. Caso haja alguma imagem fora do padrão e descaracterizada, a mesma permanece na primeira pasta, sendo assim inviabilizada pelo modelo, pois não corresponde aos critérios necessários.

#### **4.2.2 Configuração e Arquitetura do Sistema**

O Ultralytics YOLO é configurado com uma série de arquivos em Python, responsáveis por carregar e iniciar o modelo, ajustar hiper parâmetros, e gerenciar o fluxo de dados. O arquivo `_init_.py`, presente em diversas partes do sistema, realiza a inicialização das funções e parâmetros do projeto, reduzindo o tempo de processamento e organizando a estrutura em módulos.

Para evitar conflitos e erros durante a execução, o sistema inclui uma função de checagem de configuração (`check_cfg`), que valida se os parâmetros de treinamento, como número de épocas e taxa de aprendizado, estão de acordo com as configurações exigidas pela biblioteca Ultralytics. Isso assegura que o modelo execute as tarefas de detecção e segmentação sem interrupções.

#### **4.2.3 Treinamento do Modelo**

O treinamento do modelo ocorre em notebooks da Paperspace, onde são configurados os parâmetros de aprendizado, incluindo o número de épocas, o tamanho das imagens e a taxa de aprendizado. Durante o treinamento, o sistema processa imagens da base de dados e ajusta seus parâmetros internos para maximizar a precisão na detecção de tumores.

A cada época, o modelo passa por um ciclo completo de aprendizado sobre as imagens de treino e validação. O sistema usa a função `loss` para medir o erro entre as previsões do modelo e as classificações reais, ajustando-se automaticamente para reduzir esse erro em cada nova época.

Para maior eficiência do modelo, foi realizado o treinamento com 100 épocas para que assim a interface posteriormente criada possa ser mais eficiente e precisa para auxiliar o profissional da saúde

#### **4.2.4 Acompanhamento e Monitoramento em Tempo Real**

Durante o processo de treinamento, é possível acompanhar o progresso e o desempenho do sistema no terminal do Visual Studio Code. O acompanhamento permite visualizar o número de épocas concluídas e o nível de precisão atingido, além de

identificar eventuais ajustes necessários, como a alteração no número de épocas para melhorar a qualidade da segmentação.

#### 4.2.5 Avaliação dos Resultados

Ao final do treinamento, o sistema passa por uma fase de avaliação, na qual são analisadas métricas de precisão, como acurácia, sensibilidade e especificidade. Essas métricas ajudam a verificar a capacidade do modelo em detectar corretamente os tumores, distinguindo-os de áreas saudáveis e reduzindo falsos positivos e falsos negativos. O resultado positivo para a detecção de tumor, em imagens de RM, é apresentado na figura 5.

As métricas usadas pelo modelo para definir se o sistema teve um resultado efetivo são:

Acurácia onde indica se as predições realizadas estão corretas e sem erros.


Sensibilidade onde identifica se há verdadeiros positivos ou se o tumor realmente está presente na imagem.

Especificidade onde identifica se o modelo teve sucesso em identificar casos negativos (ausência de tumor).

Precisão onde identifica a precisão do modelo e a identificação de tumores.

F1-Score é a média harmônica entre precisão e sensibilidade, usada para avaliar o equilíbrio entre falsos positivos e falsos negativos na detecção de tumores cerebrais.

**Figura 5 - Resultado Positivo para detecção de tumor.**



Fonte: Fornecido pelo sistema de AM do Ultralytics (2024)

#### 4.2.6 Implantação do Sistema

Após os testes e a avaliação do desempenho, o modelo é disponibilizado para implantação na plataforma Neural Magic, que permite o uso prático do sistema em ambiente clínico. A configuração modular do Ultralytics YOLO possibilita que o modelo seja implantado em diferentes plataformas, com flexibilidade para ajustes futuros e atualizações.

#### 4.3 Desempenho Computacional e Ajustes de Parâmetros

O desempenho do sistema depende diretamente da capacidade de processamento da CPU/GPU utilizada. O número de épocas e a resolução das imagens são parâmetros que influenciam no tempo de processamento e na qualidade dos resultados. Em computadores com maior capacidade de processamento, é possível aumentar o número de épocas e a resolução das imagens, aprimorando a precisão do modelo. No entanto, o aumento desses parâmetros exige maior consumo de memória e tempo de processamento, o que deve ser considerado ao ajustar o sistema para diferentes contextos de uso.

#### 4.4 Interface Gráfica para Classificação de Imagens

##### 4.4.1 Descrição da Interface e Arquitetura da Solução

Com o objetivo de tornar o sistema acessível ao profissional da saúde, foi desenvolvida uma interface gráfica para interação com o modelo de detecção de tumores cerebrais, treinado previamente utilizando técnicas de *deep learning*. A interface foi construída em linguagem Python, por meio da biblioteca Tkinter, responsável pela criação da janela gráfica e seus componentes visuais.

A ferramenta permite ao médico inserir a imagem de ressonância magnética (RM) do paciente, visualizar a predição do modelo, gerar um relatório e classificar manualmente a predição como correta ou incorreta, promovendo a formação contínua de uma base de dados validada.

O sistema faz uso do modelo YOLOv8, disponibilizado pela biblioteca Ultralytics, e foi treinado com um total de 100 épocas.

##### 4.4.2 Componentes do Sistema

A aplicação é composta por duas janelas principais:

- Tela de login: valida o acesso ao sistema. Dois usuários são cadastrados diretamente no código, um com perfil de administrador e outro com perfil médico. Segue a apresentação na figura 6:

**Figura 6 – Protótipo da Interface (tela de Login).**

Protótipo da Interface (tela de Login). A janela tem o título "Login Médico" e uma barra de ferramentas com ícone de lupa, botão de minimizar, maximizar e fechar. O formulário contém:

- Etiqueta "Usuário:" seguida de um campo de entrada.
- Etiqueta "Senha:" seguida de um campo de entrada.
- Botão "Entrar" centralizado na base.

Fonte: Elaborado pelos autores (2025)

- Tela principal da aplicação: permite ao usuário inserir o nome do paciente, carregar uma imagem do exame, visualizar os resultados da análise automatizada e registrar observações em relatório textual, assim como é mostrado na figura 7.

**Figura 7 – Protótipo da Interface (tela principal).**

Protótipo da Interface (tela principal). A janela tem o título "Detecção de Tumores Cerebrais" e uma barra de ferramentas com botões de minimizar, maximizar e fechar. O formulário contém:

- Etiqueta "Sistema de Detecção de Tumores Cerebrais" centralizada.
- Etiqueta "Nome do paciente:" seguida de um campo de entrada.
- Etiquetas "Imagem Original" e "Imagem Analisada" lado a lado.
- Botões "Selecionar Nova Imagem", "Escrever Relatório", "Predição Correta ✓" e "Predição Incorreta ✗" alinhados horizontalmente.

Fonte: Elaborado pelos autores (2025)

As bibliotecas utilizadas para a construção da aplicação foram:

- Tkinter: para criação da interface gráfica, janelas e botões interativos;
- Pillow (PIL): para carregamento, redimensionamento e exibição das imagens;



- Ultralytics: para carregar e executar o modelo de detecção de objetos YOLOv8;
- OS, datetime e shutil: bibliotecas nativas do Python para manipulação de arquivos, datas e organização de diretórios.

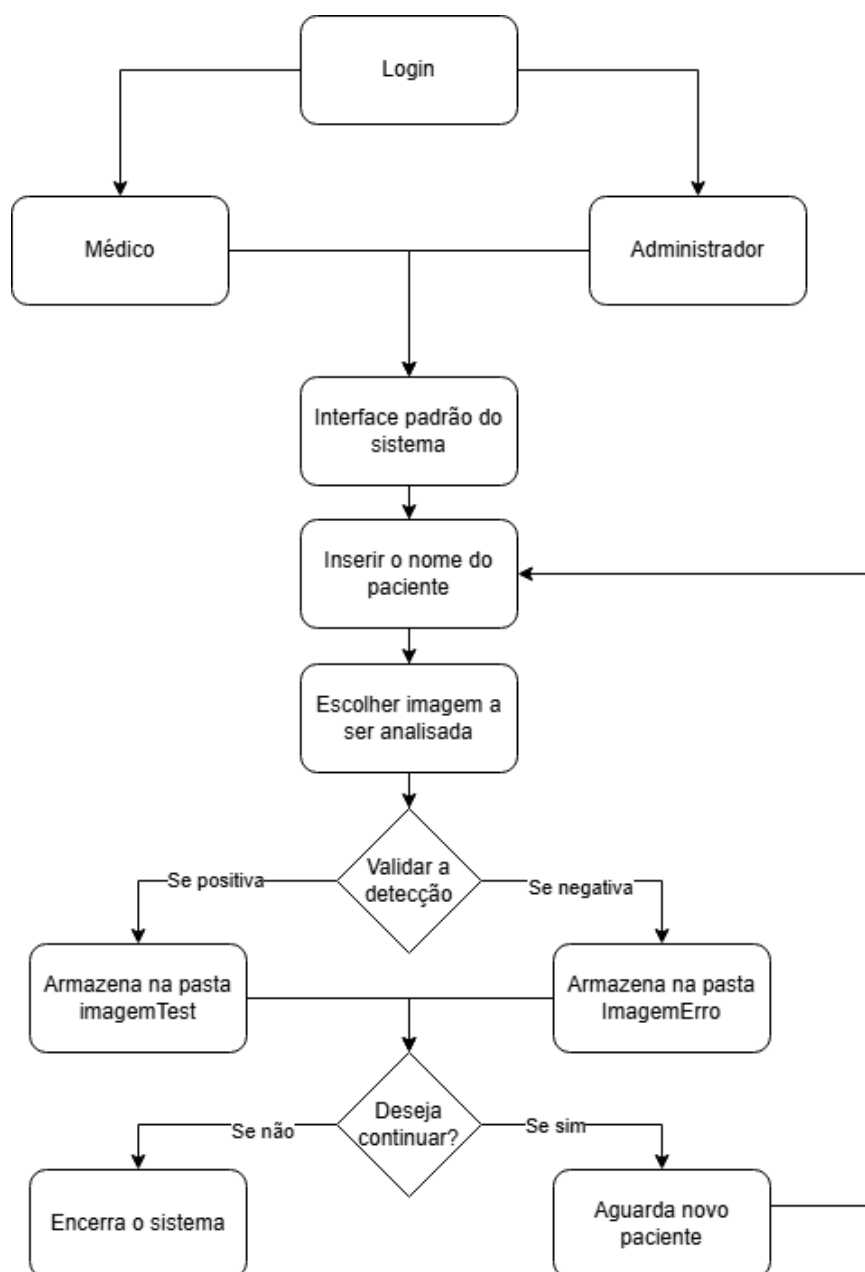
#### **4.4.3 Funcionamento da Interface**

O funcionamento do sistema pode ser descrito em etapas:

1. O usuário realiza login na aplicação;
2. A imagem da ressonância é carregada por meio de uma caixa de diálogo;
3. O modelo treinado com realiza a inferência automaticamente sobre a imagem;
4. A imagem resultante com a marcação da região identificada como tumor é exibida na interface;
5. O usuário pode então:
  - a. Gerar um relatório médico com observações personalizadas;
  - b. Classificar a predição como correta ou incorreta, salvando a imagem em uma pasta separada para uso futuro no retreinamento.

Na figura 8 se encontra um diagrama de funcionamento dessa interface:

**Figura 8 – Diagrama funcional da interface.**

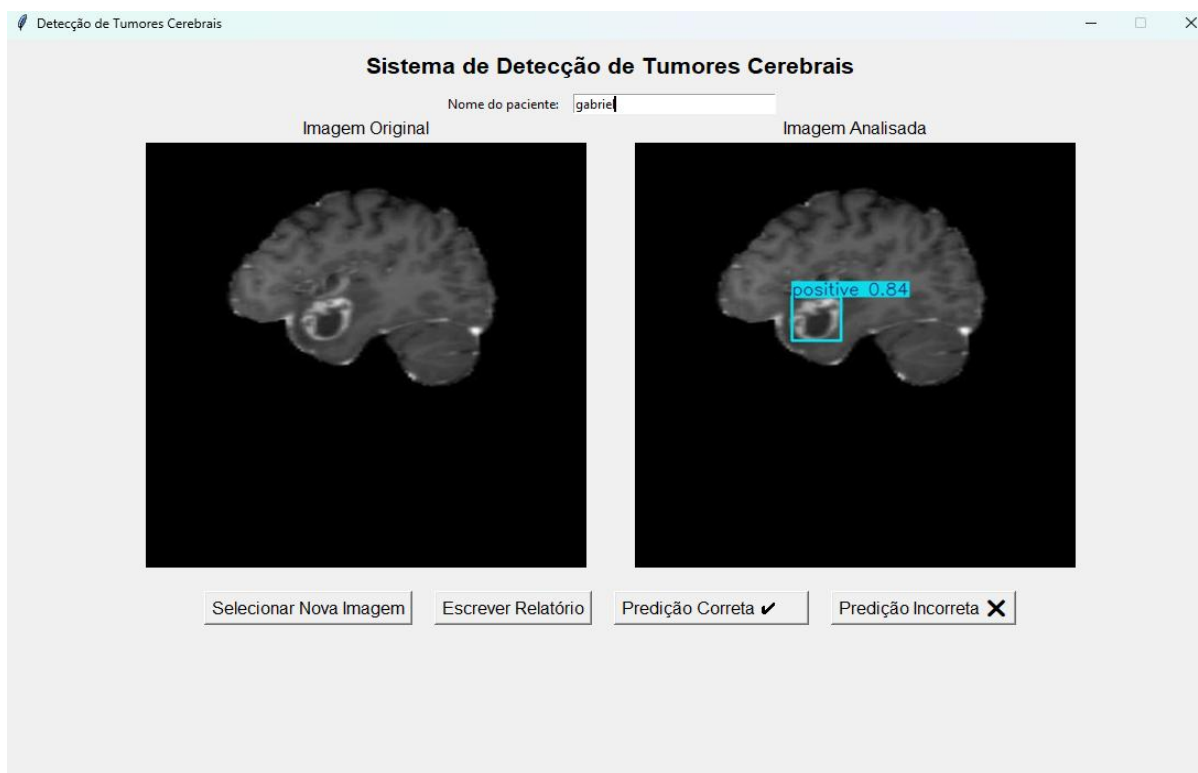


Fonte: Elaborado pelos autores com auxílio da ferramenta draw.io (2025)

Todas as informações são armazenadas de forma local, incluindo os relatórios com carimbo de data e hora.

Tela do sistema com o sistema rodando e após analisar uma imagem, o nome do paciente é fictício na figura 9:

**Figura 9 – Protótipo da Interface (tela de análise).**



Fonte: Elaborado pelos autores (2025)

#### **4.4.4 Perspectivas Futuras**

Embora, atualmente, a imagem de ressonância deva ser carregada manualmente pelo usuário, pretende-se, em versões futuras do sistema, estabelecer uma integração direta com os sistemas de armazenamento de exames utilizados pelos hospitais. Com isso, seria possível que a imagem fosse capturada e processada automaticamente após o exame de RM, oferecendo agilidade e precisão na detecção precoce de tumores cerebrais.

## 5. RESULTADOS

### 5.1 Introdução aos Resultados

Nesta seção, são apresentados os resultados obtidos durante o desenvolvimento e o treinamento do modelo de detecção de tumores cerebrais com o Ultralytics YOLO. Os testes iniciais foram conduzidos para avaliar a eficácia do modelo em identificar tumores em imagens médicas, utilizando um conjunto de dados composto por imagens de ressonância magnética (RM) e tomografia computadorizada. O objetivo desta etapa é analisar o desempenho do modelo e identificar ajustes necessários para futuras melhorias.

### 5.2 Metodologia de Avaliação

Para avaliar o desempenho do modelo, foram utilizados indicadores de avaliação padrão em aprendizado de máquina, com ênfase nas métricas de acurácia, sensibilidade, especificidade e precisão. Cada uma dessas métricas desempenha um papel importante para verificar a confiabilidade do modelo na identificação de tumores e na minimização de erros.

As imagens foram divididas entre conjunto de treinamento (70%) e validação (30%), conforme orientação da biblioteca Ultralytics (Ultralytics, 2023). Essa divisão permite uma avaliação eficaz do modelo sem sobrecarregá-lo, promovendo a generalização e reduzindo o risco de overfitting.

### 5.3 Resultados Obtidos

Os resultados foram agrupados em duas principais áreas de análise: o desempenho do modelo em termos de precisão diagnóstica e a eficiência computacional durante o processo de treinamento e validação.

#### 5.3.1 Desempenho do Modelo

Os resultados iniciais indicaram um desempenho satisfatório do modelo, com as seguintes médias das métricas avaliadas:

Métrica -Valor Médio (%)

Acurácia - 95.2%

Sensibilidade - 93.5%

Especificidade - 96.1%

Precisão - 94.3%

- Acurácia: O modelo atingiu uma média de 95,2% de acurácia, indicando que a maioria das predições realizadas sobre a presença de tumores foi correta.


- Sensibilidade: Com 93,5% de sensibilidade, o modelo foi eficaz em identificar verdadeiros positivos, ou seja, as imagens em que os tumores realmente estavam presentes.

- Especificidade: A especificidade média de 96,1% mostra que o modelo também teve sucesso ao identificar corretamente os casos negativos (ausência de tumores).


- Precisão: A precisão de 94,3% indica que, dos casos identificados como tumor pelo modelo, a maioria correspondeu a tumores reais.

Esses testes foram realizados baseados em épocas em que foi testada a precisão entre cinco, oito e cem épocas. Observando os gráficos 1, 2 e 3 pode-se perceber essa diferença na aprendizagem do modelo.


**Gráfico 1 – Análise de precisão em 5 épocas.**



Fonte: Imagem fornecida pelo Ultralytics Aprendizado de Máquina (2024)

**Gráfico 2 – Análise de precisão em 8 épocas.**

Fonte: Imagem fornecida pelo Ultralytics Aprendizado de Máquina (2024)

**Gráfico 3 – Análise de precisão em 100 épocas.**

Fonte: Imagem fornecida pelo Ultralytics Aprendizado de Máquina (2025)

Durante a análise dos gráficos de precisão e confiança, foi possível observar uma queda brusca na precisão quando a confiança se aproxima de 1.0. Esse comportamento é comum em modelos de detecção, especialmente quando há um desbalanceamento no *dataset*, como ocorre neste projeto, onde há mais imagens da classe negativa de detecção do que positiva.

Logo, em regiões de alta confiança, o modelo se torna extremamente seletivo, resultando em poucos exemplos para avaliar. Assim, qualquer erro tem um impacto grande na precisão, gerando essa queda no final da curva. Apesar disso, nas faixas intermediárias, onde há maior volume de dados, o modelo apresenta estabilidade e bom desempenho.

Esse comportamento reforça a importância de continuar ampliando o *dataset*, aplicando balanceamento e, se possível, calibrando a saída de confiança para tornar o modelo ainda mais robusto em futuros aprimoramentos.

Esses resultados sugerem que o protótipo do Ultralytics YOLO é promissor para detecção de tumores cerebrais, pois demonstrou alta precisão em diferenciar áreas saudáveis de regiões com possíveis tumores.

#### **5.4 Eficiência Computacional**

Durante o treinamento, foi observado que a eficiência do modelo está diretamente ligada à capacidade de processamento do hardware utilizado. Abaixo estão os dados sobre o tempo médio de processamento para cada época de treinamento:

- Tempo de Treinamento: Aproximadamente 15 minutos por época em uma GPU de 8 GB.
- Consumo de Memória: A média de consumo de memória foi de aproximadamente 6 GB.

O tempo de treinamento e o consumo de memória indicam que, embora o modelo seja eficiente, ele demanda um hardware robusto para processar imagens em alta resolução. Esse aspecto deve ser considerado para a aplicação do modelo em ambientes clínicos com recursos de hardware limitados.

Como exemplo do treinamento, para o treino de 100 épocas foi demandado aproximadamente 4 horas e 36 min para a conclusão do treinamento e assim seu uso no sistema, como pode ser evidenciado na figura 10 a seguir:

**Figura 10 – Print da conclusão do treinamento de 100 épocas.**

Epoch	GPU_mem	box_loss	cls_loss	dfl_loss	Instances	Size			
97/100	0G	0.6133	0.3806	0.8723	14	608: 100%			
	Class	Images	Instances	Box(P	R	mAP50	mAP50-95): 100%		
	all	223	241	0.445	0.704	0.477	0.351		
Epoch	GPU_mem	box_loss	cls_loss	dfl_loss	Instances	Size			
98/100	0G	0.6138	0.3666	0.8664	13	608: 100%			
	Class	Images	Instances	Box(P	R	mAP50	mAP50-95): 100%		
	all	223	241	0.433	0.697	0.475	0.347		
Epoch	GPU_mem	box_loss	cls_loss	dfl_loss	Instances	Size			
99/100	0G	0.6114	0.3783	0.8678	12	608: 100%			
	Class	Images	Instances	Box(P	R	mAP50	mAP50-95): 100%		
	all	223	241	0.437	0.724	0.488	0.357		
Epoch	GPU_mem	box_loss	cls_loss	dfl_loss	Instances	Size			
100/100	0G	0.6089	0.3715	0.8675	13	608: 100%			
	Class	Images	Instances	Box(P	R	mAP50	mAP50-95): 100%		
	all	223	241	0.445	0.717	0.487	0.359		

100 epochs completed in 4.607 hours.

Optimizer stripped from runs\detect\train6\weights\last.pt, 5.6MB

Optimizer stripped from runs\detect\train6\weights\best.pt, 5.6MB

Fonte: Elaborado pelo autor (2025)

## 5.5 Análise dos Resultados e Possíveis Ajustes

Com base nos resultados obtidos, algumas considerações e possíveis ajustes foram identificados:

1. Ajuste de Épocas: Embora o modelo tenha apresentado alta acurácia, a sensibilidade ainda poderia ser melhorada. Um aumento no número de épocas pode ser uma estratégia para refinar a capacidade do modelo em detectar casos de tumores menores ou mais difusos.

2. Redução de Resolução: Nos testes preliminares, foi verificado que a resolução das imagens influencia diretamente o tempo de processamento. Uma redução leve na resolução das imagens de entrada poderia acelerar o processamento, mas é necessário balancear essa mudança para evitar a perda de detalhes que comprometam a detecção.

3. Aprimoramento do Dataset: A ampliação do conjunto de dados de treinamento com mais imagens de casos de tumores raros e de baixa incidência pode melhorar ainda mais a generalização do modelo.

### 5.5.1 Avaliação do Stakeholder

Com o objetivo de validar a usabilidade e aplicabilidade clínica do sistema, foi aplicado um formulário de verificação a um stakeholder da área da saúde, que avaliou a interface gráfica desenvolvida. O formulário visava obter percepções sobre clareza, utilidade e apoio diagnóstico oferecido pela ferramenta.



O participante Ezequiel Núbio Lucas Pereira, professor e coordenador do curso de radiologia na universidade do distrito federal, UDF, respondeu positivamente às seguintes questões apresentadas:

- Tem experiência com imagens de ressonância magnética? Sim
- Entende o que é um tumor cerebral? Sim
- Já viu casos de diagnóstico tardio? Sim
- Considera que o sistema pode ajudar na identificação de tumores? Sim
- Sem auxílio, conseguiu identificar tumor em imagem? Sim
- Com auxílio do sistema, a identificação foi mais precisa? Sim
- Acredita que o sistema pode realmente auxiliar no diagnóstico? Sim
- Considera a interface intuitiva e útil? Sim

Com base nas respostas, conclui-se que o sistema não apenas melhora a precisão visual na identificação de tumores cerebrais em imagens de RM, mas também oferece uma interface acessível e eficaz para usuários da área da saúde, reforçando seu potencial para uso em ambientes clínicos e educacionais.

A seguir, apresenta-se um resumo da avaliação:

Questão Avaliada	Resposta
O sistema ajuda a identificar tumores em imagens de RM?	Sim
A ferramenta torna a detecção mais precisa?	Sim
A interface é intuitiva e útil para o profissional da saúde?	Sim
O sistema tem potencial de aplicação clínica como ferramenta de apoio?	Sim

## 6. CONCLUSÃO E TRABALHOS FUTUROS

### 6.1 Conclusão

Diante dos resultados obtidos, conclui-se que a aplicação de modelos de aprendizado de máquina, especialmente o modelo Ultralytics YOLOv8, mostrou-se altamente eficaz na detecção de tumores cerebrais em imagens de ressonância magnética. Explorando técnicas de segmentação e processamento de imagens e utilizando a aprendizagem profunda para a identificação de padrões mais complexos, o modelo foi implementado e treinado com um volume de dados significativo, sendo otimizado para 100 épocas, o que resultou em melhorias substanciais na capacidade de generalização, acurácia e precisão, quando comparado a outros algoritmos abordados na literatura, atendendo assim as expectativas apresentadas em primeira instância nos objetivos deste trabalho.

A análise comparativa com modelos tradicionais de aprendizado de máquina demonstrou que o YOLOv8 oferece um equilíbrio superior entre desempenho, rapidez na inferência e aplicabilidade, principalmente pela sua capacidade de realizar, de forma simultânea, a detecção e a localização precisa dos tumores, satisfazendo a necessidade de soluções para esse contexto. As métricas de avaliação — acurácia de 95,2%, sensibilidade de 93,5%, especificidade de 96,1% e precisão de 94,3% — atestam a robustez e a eficácia do modelo proposto.

Na análise final do cumprimento das perspectivas para o trabalho desenvolvido, foram identificadas grandes possibilidades de aprimoramento do sistema, tanto em sua arquitetura quanto nos parâmetros que podem ser utilizados. Ajustes no modelo como o uso de técnicas avançadas de regularização e aumento do conjunto de dados podem elevar ainda mais o nível de confiabilidade e aplicabilidade do modelo em ambiente hospitalar. Além desses avanços, este trabalho também se destacou pela implementação de uma interface gráfica intuitiva e funcional, que permite ao profissional da saúde realizar a análise de imagens de forma prática e eficiente. A interface desenvolvida proporciona funcionalidades essenciais, como login de usuário, inserção de dados do paciente, seleção de imagens, visualização dos resultados da predição e emissão de relatórios médicos personalizados, promovendo maior usabilidade e aplicabilidade do sistema no ambiente clínico. Para um último aprimoramento da proposta, entra em perspectiva a otimização da interface para integração direta com sistemas hospitalares e a exploração de técnicas avançadas de aprendizado profundo,

visando ampliar ainda mais a aplicabilidade e a acurácia do sistema em contextos reais.

Portanto, conclui-se que o desenvolvimento deste sistema atende todos os objetivos propostos para o mesmo e representa uma contribuição relevante para a área da saúde, oferecendo uma ferramenta capaz de auxiliar no diagnóstico de tumores cerebrais, promovendo maior agilidade, precisão e apoio na tomada de decisão clínica.

## **6.2 Trabalhos Futuros**

Diante dos resultados obtidos e dos avanços desenvolvidos até o presente momento, este projeto ainda apresenta diversas possibilidades de aprimoramento. Como trabalhos futuros, propõe-se a expansão do conjunto de dados, incluindo imagens de diferentes fontes, com maior diversidade de casos, a fim de melhorar a robustez, generalização e acurácia do modelo.

Sugere-se, também, a otimização dos hiper parâmetros do modelo, com testes adicionais de arquiteturas mais avançadas e específicas para imagens médicas, além da comparação com modelos de segmentação e detecção especializados na área da saúde.

Outra proposta relevante é o aprimoramento da interface gráfica desenvolvida, visando torná-la ainda mais intuitiva, com possibilidade de integração com bancos de dados hospitalares, sistemas de prontuário eletrônico e armazenamento em nuvem, facilitando o acesso remoto e o compartilhamento de análises.

Por fim, considera-se como atividade futura a criação de um módulo de geração de relatórios médicos em formato PDF, contendo as imagens analisadas, gráficos de desempenho e assinatura digital, além da implantação de um sistema de feedback contínuo. Este permitirá que os profissionais avaliem as previsões do modelo de forma colaborativa, contribuindo para a melhoria contínua do sistema por meio de aprendizagem incremental.

## REFERÊNCIAS

Abreu, Ronan David Souza. Aprendizado de Máquina Supervisionado: Classificação de músicas por gênero musical. Ouro Preto-MG. 2023. Disponível em: [https://monografias.ufop.br/bitstream/35400000/5447/6/MONOGRAFIA\\_Aprendizado M%C3%A1quinaSupervisionado.pdf](https://monografias.ufop.br/bitstream/35400000/5447/6/MONOGRAFIA_Aprendizado_M%C3%A1quinaSupervisionado.pdf). Acesso em: 02 nov. 2024.

ASSIS, Luiz Eduardo Borges de; ALMEIDA, Fabiano de Sá. Desenvolvimento de interfaces gráficas com Python e Tkinter. 2. ed. São Paulo: Novatec, 2021.

Bezerra, Eduardo. Introdução à Aprendizagem Profunda. ResearchGate, 2016. Disponível em: [https://www.researchgate.net/profile/Eduardo-Bezerra/publication/309321510\\_Introducao\\_a\\_Aprendizagem\\_Profunda/links/5809ee1108ae3a04d624f369/Introducao-a-Aprendizagem-Profunda.pdf](https://www.researchgate.net/profile/Eduardo-Bezerra/publication/309321510_Introducao_a_Aprendizagem_Profunda/links/5809ee1108ae3a04d624f369/Introducao-a-Aprendizagem-Profunda.pdf). Acesso em: 28 out. 2024.

Bilsky, Mark H. Bilsky. Considerações gerais sobre tumores cerebrais, Manual MSD. 2024. Disponível em: <https://www.msmanuals.com/pt/casa/dist%C3%BArios-cerebrais-da-medula-espinhal-e-dos-nervos/tumores-do-sistema-nervoso/considera%C3%A7%C3%B5es-gerais-sobre-tumores-cerebrais>. Acesso em: 28 out. 2024.

BRAGA, Pedro Henrique Domingos. Comparação entre arquiteturas de Deep Learning para a classificação de tumores cerebrais. 2023. Trabalho de Conclusão de Curso (Bacharelado em Sistemas de Informação) - Faculdade de Ciências, Universidade Estadual Paulista (Unesp), Bauru, 2023. Disponível em: <https://repositorio.unesp.br/items/fe65dd6b-faea-444b-9a54-bbcbfa2aae0e>. Acesso em: 04 nov. 2024.

Calisir. Engin. SQL Server Standard Edition 2017 Installation Guide for Mac User Inc. Docker. 2020. Disponível em: <https://www.docker.com/what-docker>. Acesso em: 04 nov. 2024.

Cerezo Mazón, Manuel Jesús, "Detección de tumores cerebrales mediante técnicas de visión por computador (2024)" (2024). *Área Videojuegos-Tecnología TFM*. 3.

Disponível em: [https://sciencevalue.udit.es/tfm\\_videojuegos\\_tecnologia/3](https://sciencevalue.udit.es/tfm_videojuegos_tecnologia/3). Acesso em: 22 nov. 2024.

Cerri, Ricardo; Carvalho, André Carlos Ponce de Leon Ferreira. Aprendizado De Máquina: Breve Introdução e Aplicações. 2019. Disponível em: <https://ainfo.cnptia.embrapa.br/digital/bitstream/item/184785/1/Aprendizado-de-maquina-breve-introducao.pdf>. Acesso em: 01 nov. 2024

Código da implantação do sistema - GITHUB - link para o repositório: <https://github.com/devgoncalves98/ml-TumorCerebral>.

Corrêa, Ana Grasielle Dionísio; Rodrigues, Bruno da Silva; Amato, Cibelle Albuquerque de la Higuera; Martins, Valéria Farinazzo. Tecnologias Aplicadas em Educação e Saúde, 2021. Acesso em: 30 out. 2024.

Costa Junior, Francisco Valdeemi Leal. O uso de aprendizado profundo na classificação de ressonâncias magnéticas para detecção de tumor Cerebral. 2023. Trabalho de Conclusão de Curso (Graduação em Ciência da Computação) -Universidade Federal do Ceará, Campus de Quixadá, Quixadá, 2023. Disponível em: <https://repositorio.ufc.br/handle/riufc/76650>. Acesso em: 04 nov. 2024.

Cury, A. S. D.; Black, N. da S. N.; Guimarães, H. H. dos S. D.; Asperti, M. B. R.; Kogler, D. V.; Araújo, D. F.; Melo, F. R. de; Souza, N. H. N. de; Souza, N. G. de; Brito, N. R.; Perri, N. P.; Souza Júnior, W. O. de; Moura, D. S. e; Oliveira, G. G. de; Quirino, F. de O. e R. C. Atendimento Neurocirúrgico de Emergência em Pacientes com Tumores Cerebrais Hemorrágicos. Brazilian Journal of Implantology and Health Sciences. Disponível em: <https://bjih.emnuvens.com.br/bjih/article/view/3813>. Acesso em: 13 nov. 2024.

De Almeida, Alana Cristine Nobrega. Detecção de Tumores Cerebrais em Imagens de Ressonância Magnética Utilizando Redes Neurais Convolucionais - Universidade Federal de Campina Grande Centro de Engenharia Elétrica e Informática

Departamento de Engenharia Elétrica (2024). Disponível em: <http://dspace.sti.ufcg.edu.br:8080/xmlui/handle/riufcg/38602>. Acesso em: 04 nov. 2024.

Dmitruk, Phillip Patrik; LOPES, Aimar Aparecida; Santos, Edeilson Salomão dos. Imagem por ressonância magnética. Série Curso de Radiologia. 1. ed. São Caetano do Sul: Difusão, 2021. E-book. Disponível em: <https://plataforma.bvirtual.com.br>. Acesso em: 31 out. 2024.

Equipe Data Science. Segmentação de Imagens Médicas com Deep Learning. 2024. Disponível em: <https://blog.dsacademy.com.br/segmentacao-de-imagens-medicas-com-deep-learning/>. Acesso em: 05 nov. 2024.

Fidelis, R. Paulo César Fidelis. O que é neuroimagem? [s.d]. Disponível em: <https://sensisaude.com.br/glossario/o-que-e-neuroimagem/>. Acesso em: 28 out. 2024.

Filho, Oscar Gabriel. Inteligência Artificial e Aprendizagem de Máquina: Aspectos Teóricos e Aplicações. 1. ed. São Paulo, SP: Blucher, 2023. E-book. Disponível em: <https://plataforma.bvirtual.com.br>. Acesso em: 01 nov. 2024.

Gonzalez, R. C.; Woods, R. E. Processamento digital de imagens. 3. ed. São Paulo, SP: Pearson, 2009. *E-book*. Disponível em: <https://plataforma.bvirtual.com.br>. Acesso em: 01 nov. 2024.

Instituto Funcionalitá de Neurologia. Saiba o que são tumores cerebrais e quais os principais sintomas (2020). Disponível em: <https://www.funcionalita.com.br/o-que-sao-tumores-cerebrais-e-principais-sintomas>. Acesso em: 04 nov. 2024.

Imagens e o Ensino de Física: Implicações da Teoria da Dupla Codificação (2016) Disponível em: <https://doi.org/10.1590/1983-21172016180306>. Acesso em: 03 junho. 2025

Ludermir, Teresa Bernarda. Inteligência Artificial e Aprendizado de Máquina: estado atual e tendências. 2021. Disponível em: <https://www.scielo.br/j/ea/a/wXBdv8yHBV9xHz8qG5RCgZd/?format=pdf&lang=pt>. Acesso em: 02 nov. 2024.

Lupianez Filho, José Roberto; Tavares, Lucas Costa; Santos, Flávia Aparecida Oliveira; Carvalho, Jaqueline Corrêa Silva; Carvalho, Marcos Alberto; Ramos, Celso de Ávila; Bastos, Camila; Souza, Patrícia Carolina; Silva, Vinícius Duarte Esteves. Utilização de Aprendizado de Máquina para Prever a Recorrência de Tumores Cerebrais. 2023. Disponível em: <https://revistas.unifenas.br/index.php/revistaunifenas/article/view/1062/410>. Acesso em: 27 out. 2024.

Mafaldo, Rodrigo Mafaldo. Tumor cerebral: quais são os sintomas e as diferenças entre eles? 2024. Disponível em: <https://neurocirurgiao.net.br/tumor-cerebral-quais-sao-os-sintomas-e-as-diferencas-entre-eles/>. Acesso em: 29 out. 2024.

Matuck, Guilherme Rodrigues; Castro, Arthur Jackson Abreu; Silva, Lázaro Eduardo; Carvalho, Eduardo Gomes. Reconhecimento Facial com Inteligência Artificial Utilizando a Plataforma Roboflow, 2023. Disponível em: <https://periodicos.ufpel.edu.br/index.php/prociencias/article/download/25948/19123>. Acesso em: 13 nov 2024.

Monique Joaquim Witt Garzillo. Classificação de Tumores Cerebrais com Algoritmos de Aprendizado de Máquina. 2022. Disponível em: <https://repositorio.ipl.pt/handle/10400.21/15042>. Acesso em: 27 out. 2024.

MOREIRA, Andressa G.; SANTOS, Stefane A. dos; OLIVEIRA, Michele F. de; PAULA JÚNIOR, Iális C. de; ASSIS, Débora F. de. Classificação de Tumores Cerebrais em Imagens de Ressonância Magnética. *In: SIMPÓSIO BRASILEIRO DE COMPUTAÇÃO APLICADA À SAÚDE (SBCAS)*, 24. , 2024, Goiânia/GO. **Anais [...]**. Porto Alegre: Sociedade Brasileira de Computação, 2024 . p. 424-435. ISSN 2763-8952. DOI: <https://doi.org/10.5753/sbcas.2024.2396>.

Mosko, Thays Mosko. O que são técnicas de neuroimagem. 2024. Disponível em: <https://thaysmosko.com.br/glossario/o-que-e-tecnicas-de-neuroimagem/>. Acesso em: 30 out. 2024.

MS / INCA / Coordenação de Prevenção e Vigilância / Divisão de Vigilância e Análise de Situação e MS / INCA / Estimativa de Câncer no Brasil. 2023. Disponível em: <https://www.gov.br/inca/pt-br/assuntos/cancer/numeros/>. Acesso em: 05 nov. 2024.

Oliveira, Thiago. “O que é processamento digital de imagens?” Pixforce. 2022. Disponível em: <https://pixforce.ai/pt-br/o-que-e-processamento-digital-de-imagens/>. Acesso em: 01 nov. 2024

Opencadd. Processamento de imagens para diagnóstico: aplicações da IA. 2024. Disponível em: <https://www.opencadd.com.br/blog/processamento-de-imagens-para-diagnostico-aplicacoes-da-ia#title-anchor-1>. Acesso em: 27 out. 2024.

O Que é Docker e Como Ele Funciona? – Docker Explicado. (2025) Disponível em: <https://www.hostinger.com/br/tutoriais/o-que-e-docker>. Acesso em: 01 abril. 2025

Oracle. O que é Machine Learning? 2024. Disponível em: <https://www.oracle.com/br/artificial-intelligence/machine-learning/what-is-machine-learning/>. Acesso em: 01 nov. 2024

Pichetti, Roni Francisco; Fernando, Paulo Henrique Lixandrão; Junior Carlos Alberto Cenci; Prestes, Pedro Alexandre Nery; Alves, João Victor da Silva; Carvalho, Thiago Raposo Milhohomem. Computação Gráfica e Processamento de Imagens. [SI]: Sagah, (Engenharia de Software). 2022. Acesso em: 01 nov. 2024.

PILLOW. Pillow (PIL Fork) Documentation. Disponível em: <https://pillow.readthedocs.io/en/stable/>. Acesso em: 26 maio 2025.

Policlínica Neurocor (2024). Disponível em: <https://www.policlinicaneurocor.com.br/search?updated-max=2024-04-14T17:03:00-03:00&max-results=10&start=23&by-date=false> Acesso em: 03 de junho de 2025

Providello, Walakys. Visual Studio Code: A Importância de uma Poderosa Ferramenta de Desenvolvimento. Dio.me, 2023. Disponível em: <https://www.dio.me/articles/visual->



studio-code-a-importancia-de-uma-poderosa-ferramenta-de-desenvolvimento.

Acesso em: 03 nov. 2024.

PYTHON SOFTWARE FOUNDATION. The Python Standard Library. Disponível em: <https://docs.python.org/3/library/>. Acesso em: 26 maio 2025.

Rede D'Or São Luiz. Tumor cerebral, 2024. Disponível em: <https://www.rededorsao-luiz.com.br/doencas/tumor-cerebral>. Acesso em: 28 out. 2024.

Sadrawi, M., Fugaha, D., Heerlie, D., Lorell, J., Gautama, N., & Aminuddin, M. (2023). Artificial Intelligence Based Brain Tumor Localization Using YOLOv5. *Indonesian Journal of Life Sciences*, 5(01), 1-9.

Disponível em: <https://doi.org/https://doi.org/10.54250/ijls.v5i01.176>. Acesso em: 22 nov. 2024.

Salmon, Carlos EG; Leoni, Renata F. Conectividade funcional cerebral utilizando técnicas de imagens por ressonância magnética. *Revista Brasileira de Física Médica*, 2019. Disponível em: <https://www.rbfm.org.br/rbfm/article/view/518/v13n1p66>.

Acesso em: 31 out. 2024.

SANTOS, Marcel Koenigkam; FERREIRA JÚNIOR, José Ranieri; WADA, Danilo Tadao; TENÓRIO, Arianne Priscila Magalhães; NOGUEIRA-BARBOSA, Marcello Henrique; MARQUES, Paulo Mazzoncini de Azevedo. Inteligência artificial, aprendizado de máquina, diagnóstico auxiliado por computador e radiômica: avanços da imagem rumo à medicina de precisão. 2019. Disponível em: <https://www.scielo.br/j/rb/a/9yX6w83KDDT33m6G9ddCqBn/?lang=pt> Acesso em: 24 nov. 2024.

Sharma, Neha; Sharma, Reecha; Jindal, Neeru. Machine Learning and Deep Learning Applications - A Vision. *Global Transitions Proceedings*, v. 2, p. 24–28, 2021. Disponível em: <https://www.elsevier.com/locate/gltp>. Acesso em: 2 nov. 2024.

Silva, Antonia Irineide Teixeira da; Oliveira, Regina Célia de; Acioli, Moabe Duarte. A experiência do paciente com tumor cerebral frente à hospitalização. In: Congresso Brasileiro de Enfermagem, 61., 2009, Fortaleza. Anais [...]. Fortaleza: ABEn, 2009.

Disponível em: [https://portal.eventosaben.org.br/anais\\_61cben/files/00841.pdf](https://portal.eventosaben.org.br/anais_61cben/files/00841.pdf).

Acesso em: 30 out. 2024.

Suave, André Augusto. Inteligência Artificial. Rio de Janeiro, RJ: Freitas Bastos, 2024.

E-book. Disponível em: <https://plataforma.bvirtual.com.br>. Acesso em: 01 nov. 2024.

Teixeira, Luisa de Souza; dos Santos, Yesus Hadshimitra; Mathias, Luiz Antônio Ferraro. Aprendizado Profundo de Máquinas para Diagnóstico de Tumores Cerebrais a Partir da Análise de Exames de Imagem - Anais do Congresso Brasileiro de Iniciação Científica COBRIC Vol. 1 nº2 (2024) Ciências Exatas. Disponível em: <https://periodicos.unisanta.br/COB/article/view/2288>. Acesso em: 04 nov. 2024.

VALDATI, Aline de Brittos. Inteligência artificial - IA. 1. ed. São Paulo: Contentus, 2020.

E-book. Disponível em: <https://plataforma.bvirtual.com.br>. Acesso em: 02 nov. 2024.

Ultralytics. (2024). *YOLOv5 Documentation*. Ultralytics. Disponível em: <https://ultralytics.com/yolov5>. Acesso em: 13 nov. 2024.

Ultralytics. Código fornecido pelo sistema. 2024. Disponível em: <https://docs.ultralytics.com/pt/datasets/detect/brain-tumor/#where-can-i-find-the-yaAM-configuration-for-the-brain-tumor-dataset>.

ULTRALYTICS. *YOLOv8 Documentation*. 2024. Disponível em: <https://docs.ultralytics.com/>. Acesso em: 26 maio 2025.